

# 머신 러닝의 이해

Understanding Machine Learning

# 머신 러닝의 이해

## CONTENTS

<b>1. 머신 러닝의 개요</b>	<b>02</b>
1-1 인공지능(Artificial Intelligence)이란?	
1-2 머신 러닝의 목적	
1-3 머신 러닝의 구성	
1-4 머신 러닝의 프로세스	
1-5 머신 러닝의 학습 방법	
<b>2. 머신 러닝의 분류</b>	<b>09</b>
2-1 지도 학습(Supervised Learning)	
2-2 비지도 학습(Unsupervised Learning)	
<b>3. 머신 러닝 모델 평가</b>	<b>29</b>
3-1 수치 예측 모델 평가	
3-2 범주 예측 모델 평가	
3-3 클러스터링 모델 평가	
<b>4. 데이터 분할</b>	<b>34</b>
4-1 데이터셋(Dataset)의 종류	
4-2 K-겹 교차 검증(K-fold Cross Validation)	

## 1. 머신 러닝의 개요

### 인공지능이란?

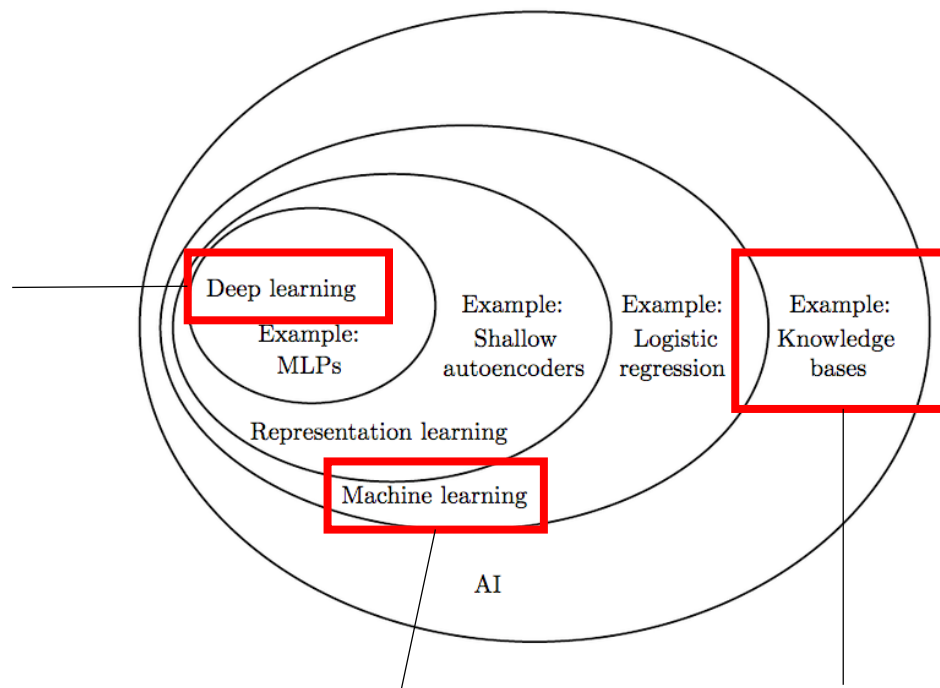
Artificial Intelligence

“의사결정이 가능한 기계”

$AI \supset ML \supset DL$

#### 딥 러닝 (Deep Learning)

많은 데이터를 바탕으로  
의사결정이 가능한 규칙과 적절한  
특징(feature)들을 기계가 생성



#### 머신 러닝 (Machine Learning)

많은 데이터를 바탕으로 의사결정이  
가능한 규칙을 기계가 생성

#### 규칙 기반 전문가 시스템

(Rule-based Expert System)  
전문가의 지식을 바탕으로 의사결정이  
가능한 규칙을 사람이 생성

## 1. 머신 러닝의 개요

### 머신 러닝의

Machine Learning

### 목적

#### 머신 러닝의 주 목적은

데이터의 알려진 속성들을 학습하여 예측 모델을 만드는 데 있다.

**예측** Prediction

수치를 예측하는 것

**분류** Classification

미리 정해진 카테고리 중 어디에 속하는지 판별

**클러스터링** Clustering

같이 자주 발생하는 연관성, 패턴 찾기

**연관관계 분석** Association Analysis

비슷한 성격의 항목들을 그룹으로 만들기

**추천** Recommender

대부분 분석의 결론은 추천의 형태를 갖는다

#### 통계와 머신 러닝의 차이는?

- 통계는 원인을 찾기 위한 목적 ⇒ (현상의 이해와 설명, 데이터 분포, 특성 파악)
- 머신 러닝은 예측을 위한 목적

# 머신 러닝의 Machine Learning 구성

머신 러닝은 학습, 모델, 알고리즘으로 구성된다.

## Learning

데이터를 기반으로 규칙을 만드는 과정 (분류 기준 생성)

## Model

분류 예측 추정 등의 목적에 부합하는 데이터 처리가 가능한 집합체

예) KNN, Linear 모델, Decision Tree, SVM, PCA, NMF, K-Means, DBSCAN, CNN, RNN, GAN, LSTM, GRU

## Algorithm

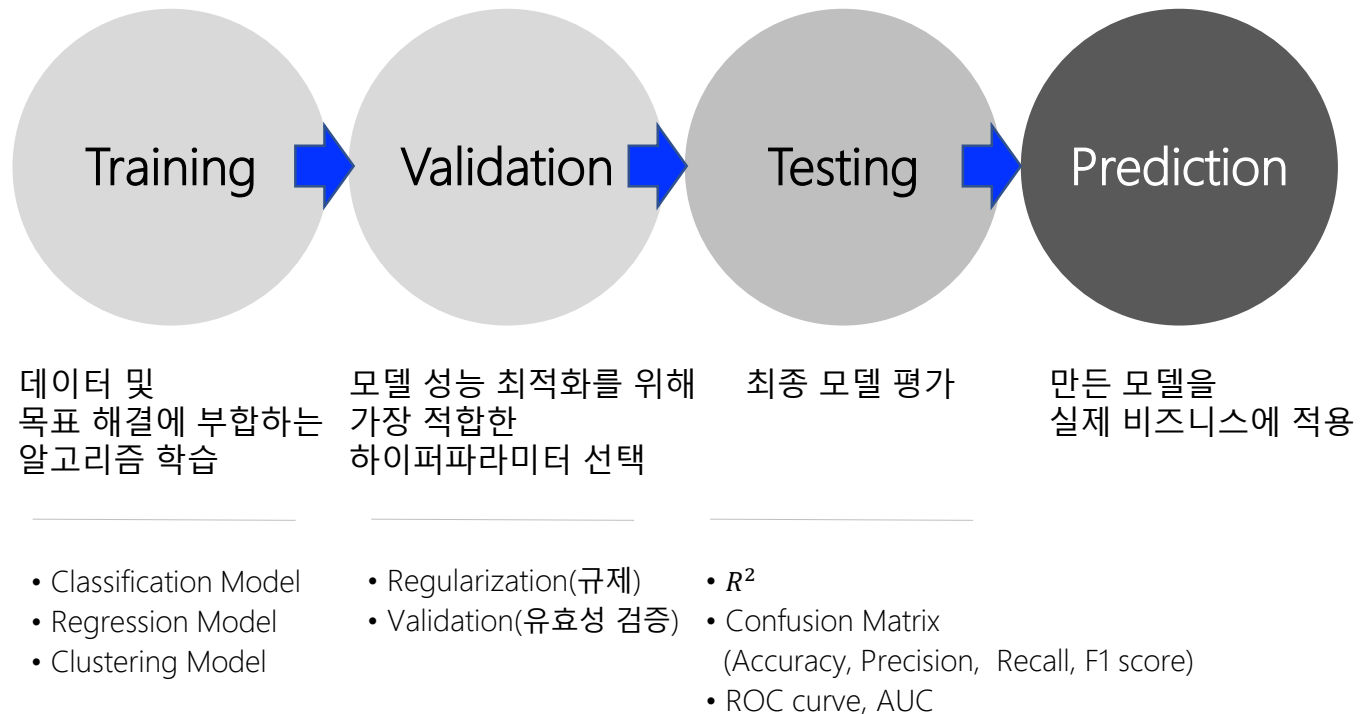
모델을 최적화 하기 위한 학습방법

예) Loss Function and Optimization  
: 최소제곱법(Least Squared), 경사하강법(Gradient Descent),  
역전파(Backpropagation), 엔트로피 최소화(Entropy)

## 1. 머신 러닝의 개요

### 머신 러닝의 Machine Learning 프로세스

1. 데이터 기반 학습을 통해 적절한 **알고리즘을 선택**하고
2. **모델을 완성**하여
3. **새로운 데이터를 예측**한다.



## 1. 머신 러닝의 개요

### 머신 러닝의

Machine Learning

### 프로세스

변수 Variable, Feature, Attribute, Factor, Field, Column, ...

### 현상들을 설명/표현하는 요소

- Predictor variables(예측변수)
- Input variables(입력변수)
- Independent(독립변수)
- Target variables(타겟변수)
- Output variables(출력변수)
- Dependent variables(종속변수)

### 현상을 측정하는 단위

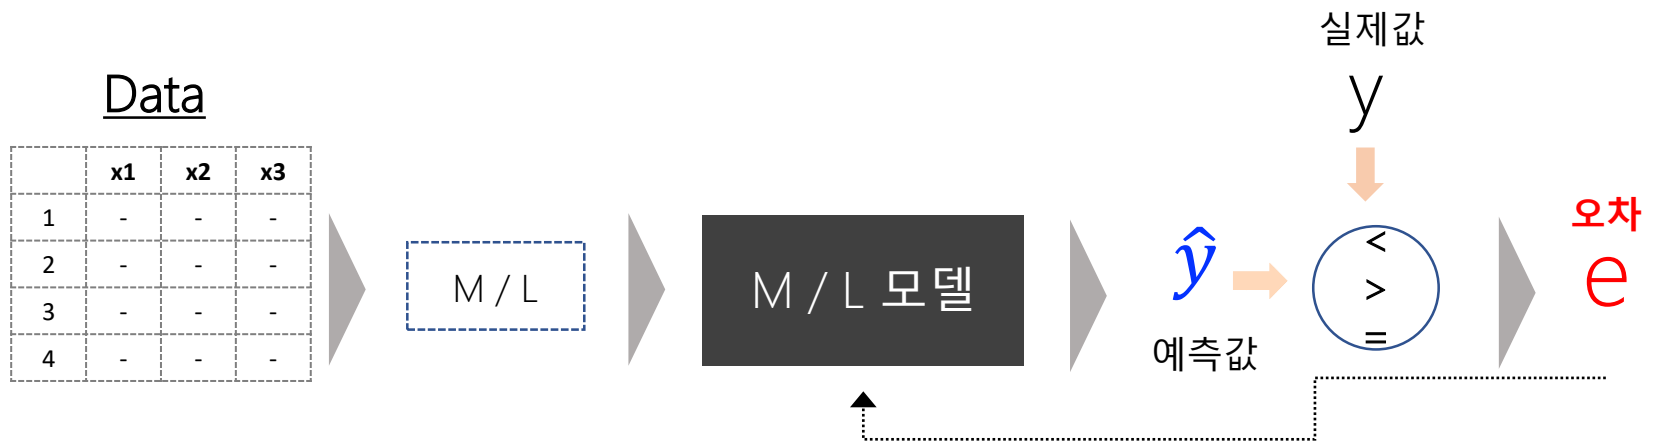
- Point(포인트)
- Sample(샘플)
- Instance(인스턴스)
- Record(레코드)
- Observation(관측치)

id	$X_1$	$X_2$	...	$X_p$	$Y$
1	$x_{11}$	$x_{12}$	...	$x_{1,p}$	$y_1$
2	$x_{21}$	$x_{22}$	...	$x_{2,p}$	$y_2$
...	...	...	...	...	...
$n$	$x_{n,1}$	$x_{n,2}$	...	$x_{n,p}$	$y_n$

## 1. 머신 러닝의 개요

### 머신 러닝의 Machine Learning 프로세스

### 머신 러닝의 분석 패턴



학습알고리즘

: 오차값이 최소화 되도록 반복 학습



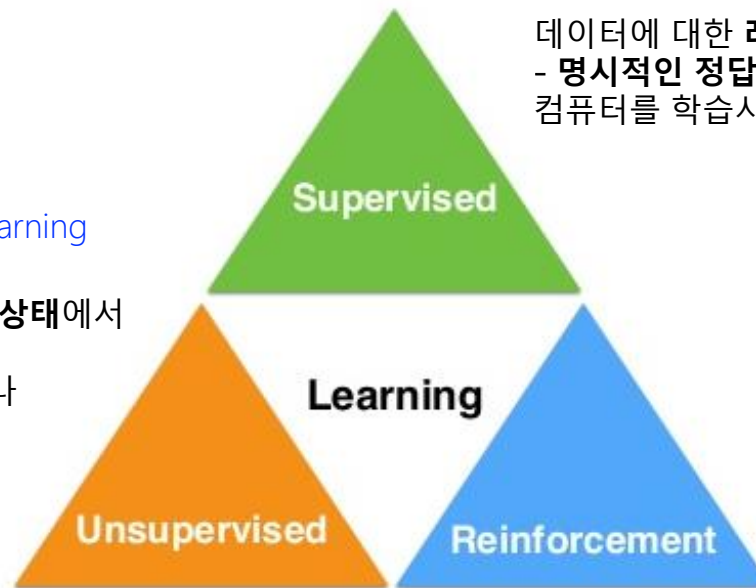
## 2. 머신 러닝의 분류

### 머신 러닝의 Machine Learning 학습 방법

머신 러닝의 학습 방법에는 지도 학습, 비지도 학습, 강화 학습이 있다.

#### 비지도 학습 Unsupervised Learning

데이터에 대한 레이블(Label)  
- 명시적인 정답이 주어지지 않은 상태에서  
컴퓨터를 학습시키는 방법  
데이터의 숨겨진 특징(Feature)이나  
구조를 발견



#### 지도 학습 Supervised Learning

데이터에 대한 레이블(Label)  
- 명시적인 정답이 주어진 상태에서  
컴퓨터를 학습시키는 방법

#### 강화 학습 Reinforcement Learning

행동심리학에서 영감을 받았으며, 어떤 환경 안에서 정의된  
에이전트가 현재의 상태를 인식하여, 선택 가능한 행동들 중  
보상을 최대화하는 행동 혹은 행동 순서를 선택하는 방법

## 2. 머신 러닝의 분류


### 머신 러닝의 Machine Learning 학습 방법

#### 지도 학습(Supervised Learning)

##### 회귀 Regression

타겟 변수  $Y$ 가 연속형(Continuous),  
범주형(Real Number) 일 때


예) - 내일 KOSPI 증가 예측  
- 다음 달 매출액 예측



##### 분류 Classification

타겟 변수  $Y$ 가 이산형(Discrete),  
범주형(Categoria) 일 때

예) - 제품의 불량/ 정상 예측  
- 메일의 스팸 예측  
- 얼굴 인식



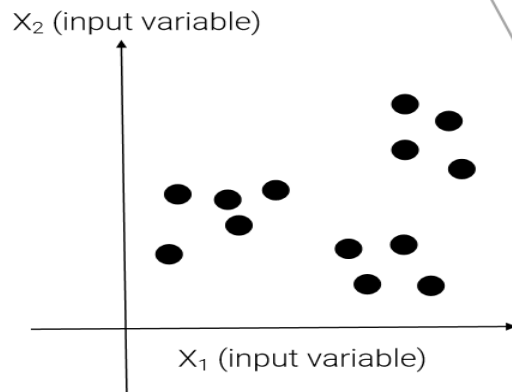
## 2. 머신 러닝의 분류

### 머신 러닝의 Machine Learning 학습 방법

#### 비지도 학습(Unsupervised Learning)


##### Learning algorithm

Find an optimal structure of clusters.



##### Model or Structure of clusters

Cluster IDs for each point



#### 군집화 Clustering

유사한 포인트들끼리 모아 군집 구조를 만드는 방법

#### 분포 추정 Density Estimation

관측된 샘플의 확률 분포를 추정하는 방법

#### 연관 규칙 분석 Association Rule Mining

아이템 간의 연관 규칙을 확률 기반으로 평가

#### 잠재 요인 추출 Extracting Latent Factors

데이터 내 잠재되어 있는 새로운 변수/요인 추출

## 2. 머신 러닝의 분류

### 머신 러닝의

Machine Learning

### 학습 방법

### 머신 러닝 모델의 분류

구분	지도 학습	비지도 학습	강화 학습
분류	KNeighborsClassifier Logistic Regression Linear SVC Naïve bayes Decision Tree RandomForest GradientBoosting SVM Feed-Forward Network CNN RNN LSTM	MinMaxScaler StanadScaler PCA NMF t-SNE K-means Agglomerative Clustering DBSCAN Autoencoders	
회귀	KNeighborsRegressor Linear regression Ridge regression Rasso regression Elastic-Net regression		
기타			Q-Learning Deep-Q-Learning

## 2. 머신 러닝의 분류

### 2-1. 지도 학습

#### 선형 회귀 모델(Linear Regression Model)


#### 수치 예측

Regression Model

연속형 타겟 변수(continuous target variable) 와  
여러 입력 변수들(input variable)의 관계를 만드는 모델


Simple Linear Regression

$$\hat{y} = w_0 + w_1 x_1$$



Multiple Linear Regression


$$\hat{y} = w_0 + w_1 x_1 + w_2 x_2 + \dots + w_n x_n$$



\*3차원 이상일 때는 hiperplane

Polynomial Linear Regression

$$\hat{y} = w_0 + w_1 x_1^6 + w_2 x_1^5 + w_3 x_1^4 + \dots$$



$$Y = \underbrace{w_0}_{\text{Intercept (절편)}} + \underbrace{w_1 x_1 + w_2 x_2 + w_3 x_3 + \dots + w_n x_n}_{\text{Coefficients (계수, 가중치, 웨이트)}} + \underbrace{\epsilon}_{\text{Error (오차, 잔차, 손실)}}$$

## 2. 머신 러닝의 분류

### 2-1. 지도 학습

#### 수치 예측


Regression Model

#### 선형 회귀 모델(Linear Regression Model) - 학습 방법

#### 손실 함수의 값을 최소화 하는 계수 찾기

손실 함수(Loss Function) = 기존 값과 예측 값의 차이

$$RSS(w_0, w_1) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - (w_0 + w_1 x_i))^2$$



\* Simple Linear Regression Case

## 2. 머신 러닝의 분류

### 2-1. 지도 학습

#### 범주 예측

Classification Model

#### 로지스틱 회귀(Logistic Regression)


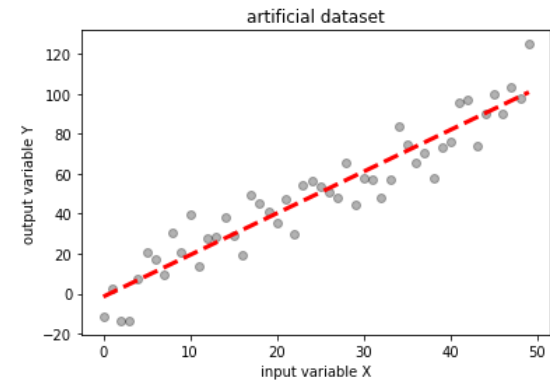
회귀선을 이용해 분류에 활용 → Sigmoid 함수 이용

##### Linear Regression

선형 함수의 회귀 최적선을 찾는 것

##### Logistic Regression

Logistic 함수의 최적선을 찾고 반환값을 확률로 간주하는 것



2. 머신 러닝의 분류


2-1. 지도 학습

범주 예측  
Classification Model

로지스틱 회귀(Logistic Regression) – 예측(Prediction)

cut-off value 이용

- 일반적인 선택 : cut-off = 0.5
- 예측 성능을 높이기 위하여 검증 데이터 (Test set)를 고려하여 최적의 cut-off value를 찾는 방법도 있음



$$\Pr(Y = 1) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p)}}$$

$X_1$	$X_2$	...	$X_p$	$Y$
$x_{11}$	$x_{12}$	...	$x_{1p}$	1
$x_{21}$	$x_{22}$	...	$x_{2p}$	0
...	...	...	...	...
$x_{i1}$	$x_{i2}$	...	$x_{ip}$	0
...	...	...	...	...
$x_{n1}$	$x_{n2}$	...	$x_{np}$	1

$P(Y = 1)$	$\hat{Y}$	$\hat{Y}$	$\hat{Y}$
0.9745	1	1	1
0.4521	1	0	0
...	...	...	...
0.5472	1	1	0
...	...	...	...
0.3541	1	0	0

cut-off = 0.3

cut-off = 0.7



## 2. 머신 러닝의 분류

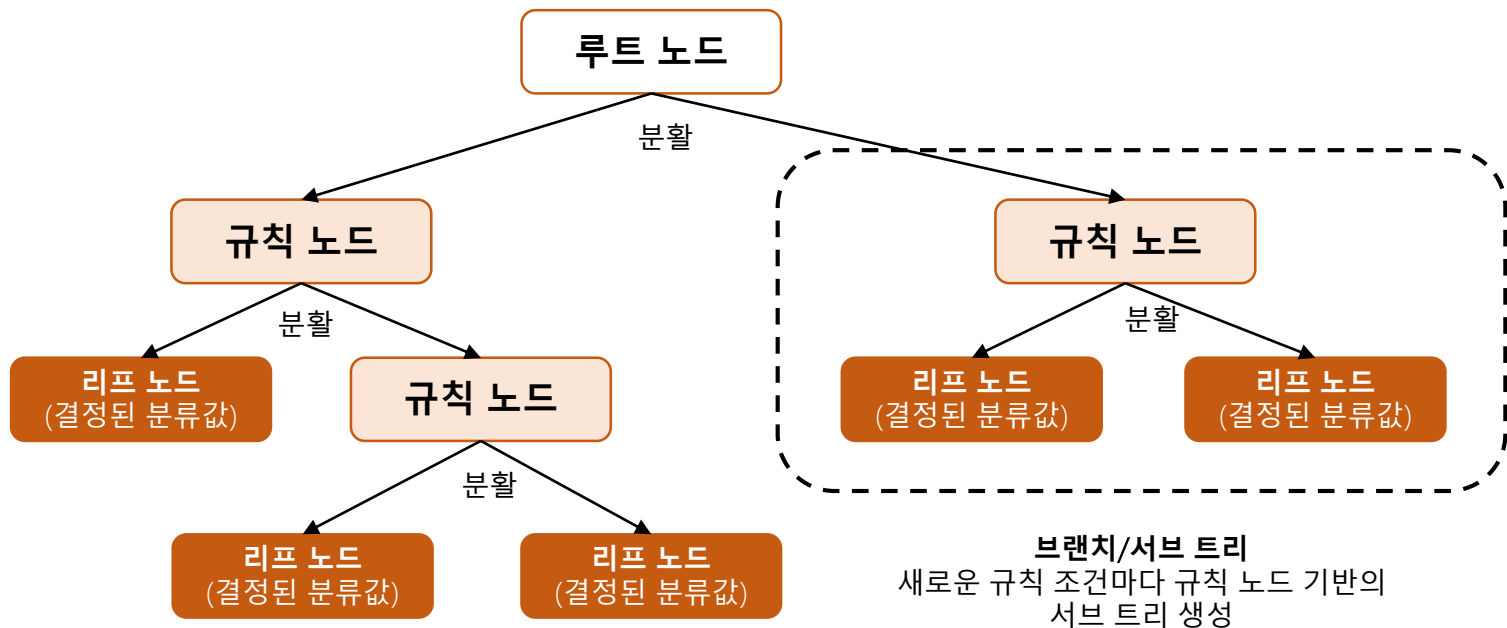
### 2-1. 지도 학습

#### 의사결정나무 모델(Decision Tree Model)

#### 범주 예측

Classification Model

결정 트리(Decision Tree)는 데이터에 있는 규칙을 학습을 통해 자동으로 찾아내 트리(Tree) 기반의 분류 규칙을 만드는 것 → 따라서 데이터의 어떤 기준을 바탕으로 규칙을 만들어야 가장 효율적인 분류가 될 것인가가 알고리즘의 성능을 크게 좌우한다.



## 2. 머신 러닝의 분류

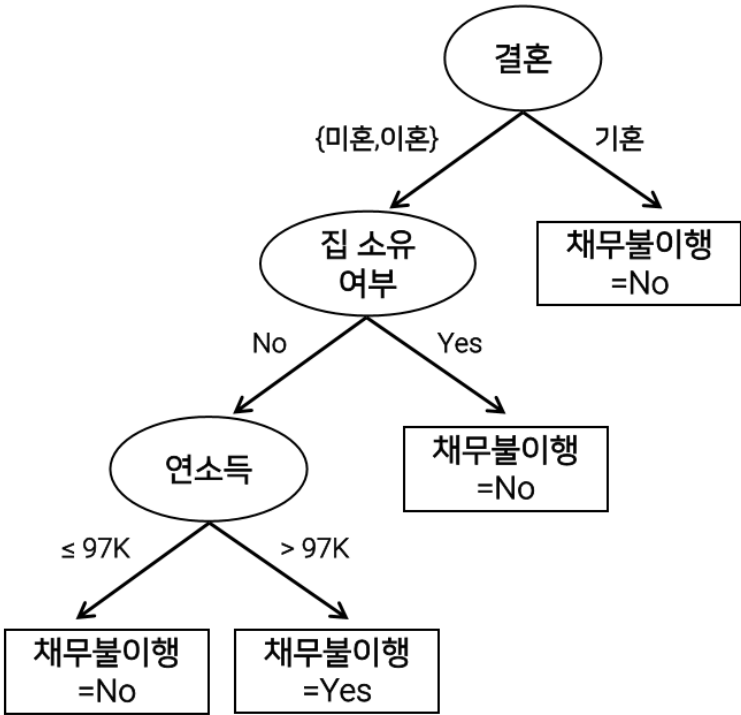
### 2-1. 지도 학습

#### 범주 예측

Classification Model

#### 의사결정나무 모델(Decision Tree Model) - CART(Classification and Regression Tree)

다음과 같이 새로운 데이터가 주어지면, 미리 학습 데이터를 이용하여, 구축한 의사결정나무 모델을 이용하여 새로운 데이터의 채무불이행 여부를 예측



ID	집 소유	결혼	연소득(K)	채무 불이행	예측 클래스
11	No	미혼	55	?	No
12	Yes	기혼	80	?	No
13	Yes	미혼	110	?	No
14	No	기혼	95	?	No
15	No	이혼	300	?	Yes

## 2. 머신 러닝의 분류

### 2-1. 지도 학습

#### 범주 예측

Classification Model

### 의사결정나무(Decision Tree Model) – 앙상블 학습(Ensemble Learning)

여러 개의 분류기(Classifier)를 생성하고 그 예측을 결합함으로써 보다 정확한 최종 예측을 수행

#### 앙상블 학습 유형:

구분	지도학습	비고
<b>보팅</b> Voting	서로 다른 알고리즘이 같은 데이터 세트에 대해 학습하고 예측한 결과를 보팅	<b>서로 다른 알고리즘 기반</b>
<b>스태킹</b> Stacking	스태킹은 여러가지 다른 모델의 예측 결과값을 다시 학습데이터로 만들어 다른 모델로 재학습시켜 결과를 예측하는 방법	
<b>배깅</b> Bagging	단일 결정 트리로 데이터 샘플링을 서로 다르게 가져가면서 학습을 수행해 보팅	<b>결정 트리 알고리즘 기반</b>
<b>부스팅</b> Boosting	여러 개의 분류기가 순차적으로 학습하면서 앞에서 학습한 분류기가 틀린 데이터에 대해서는 가중치를 부여하면서 학습과 예측을 진행	

## 2. 머신 러닝의 분류

### 2-1. 지도 학습

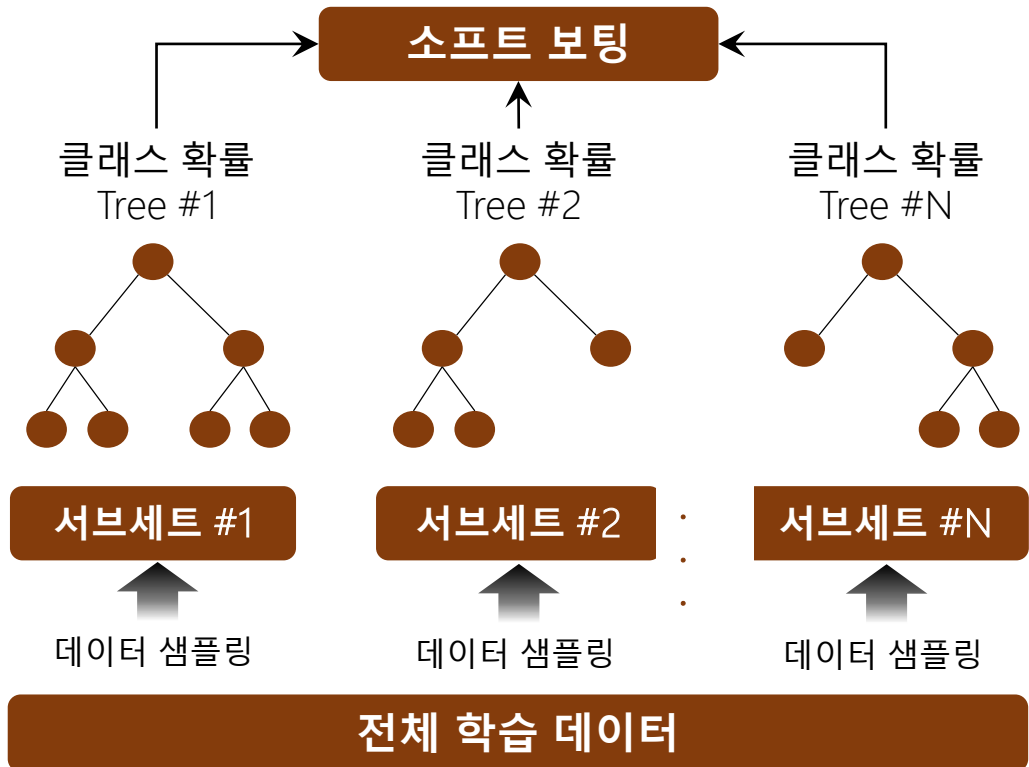
#### 범주 예측

Classification Model

#### 랜덤 포레스트(Random Forest)

여러 개의 결정 트리 분류기가 전체 데이터에서 배깅 방식으로 각자의 데이터를 샘플링해 개별적으로 학습을 수행한 뒤 최종적으로 모든 보팅을 통해 예측 결정

#### 최종 클래스 값 결정



## 2. 머신 러닝의 분류

### 2-1. 지도 학습

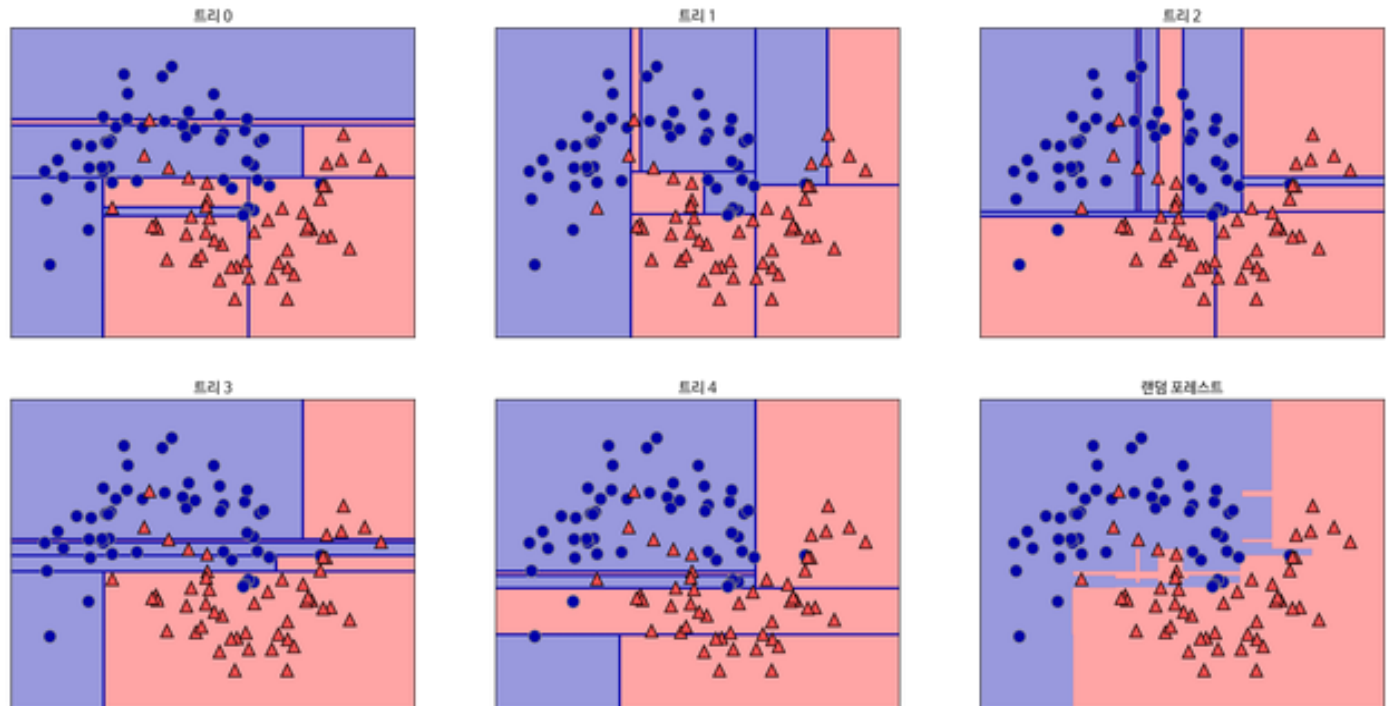
#### 범주 예측

Classification Model

#### 랜덤 포레스트(Random Forest) - Hyperparameter

- **매개변수**( $n_{\text{estimators}}$ ) : 결정 트리의 개수 (디폴트 10개)
- **max\_feature** : 결정 트리에 사용된 max\_features 파라미터와 동일
- **max\_depth**나 **min\_sample\_leaf**와 같이

결정 트리에서 과적합을 개선하기 위해 사용되는 파라미터가 랜덤 포레스트에도 똑같이 적용



## 2. 머신 러닝의 분류

### 2-1. 지도 학습

#### 범주 예측

Classification Model

#### 나이브 베이즈 분류(Naïve Bayes Classification)

**나이브 베이즈 분류기(Naïve Bayes Classifier)**란, Bayes 정리에 기반을 두는 분류기로 가장 확률이 높은 곳으로 단순 분류

#### Naïve Bayes Classification 개념

- $n$  개의 특성을 가지는 데이터 벡터 :  $X = (x_1, x_2, \dots, x_n)$
- $K$  개의 가능한 확률적 결과들 (클래스)의 확률 :

$$P(C_k | x_1, x_2, \dots, x_n) = P(C_k | X) = \frac{P(C_k) \cdot P(X | C_k)}{P(X)}$$

- 각  $x_i$  값들을 독립으로 가정하면  $= P(C_k) \prod_{i=1}^n P(x_i | C_k)$
- 클래스 예측 값  $\leftarrow$  최대 확률을 가지는 클래스

$$\hat{y} = \arg \max_{k \in \{1, \dots, K\}} P(C_k) \prod_{i=1}^n P(x_i | C_k)$$

## 2. 머신 러닝의 분류

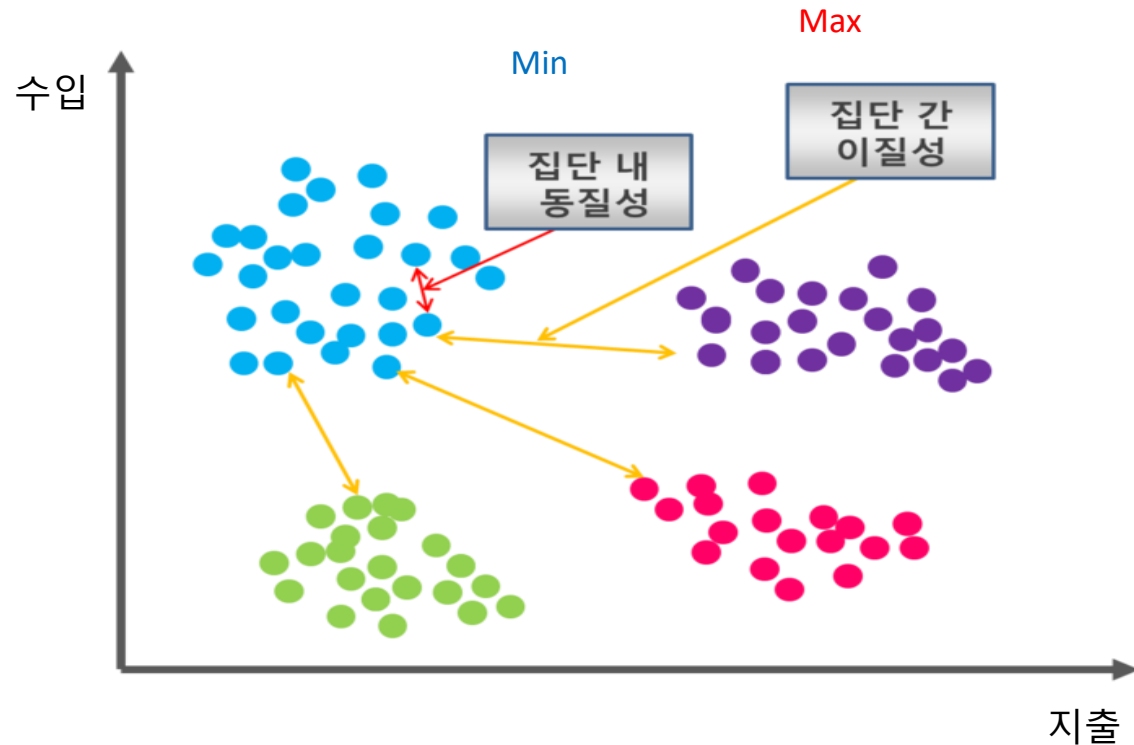
### 2-2. 비지도 학습

#### 군집 분석

Clustering

#### 군집 분석(Clustering)의 원리

거리가 가까운 데이터끼리 묶어 줌 (거리 distance 감소 = 유사도 similarity 증가)  
서로 다른 배타적인 집단으로 나누는 것



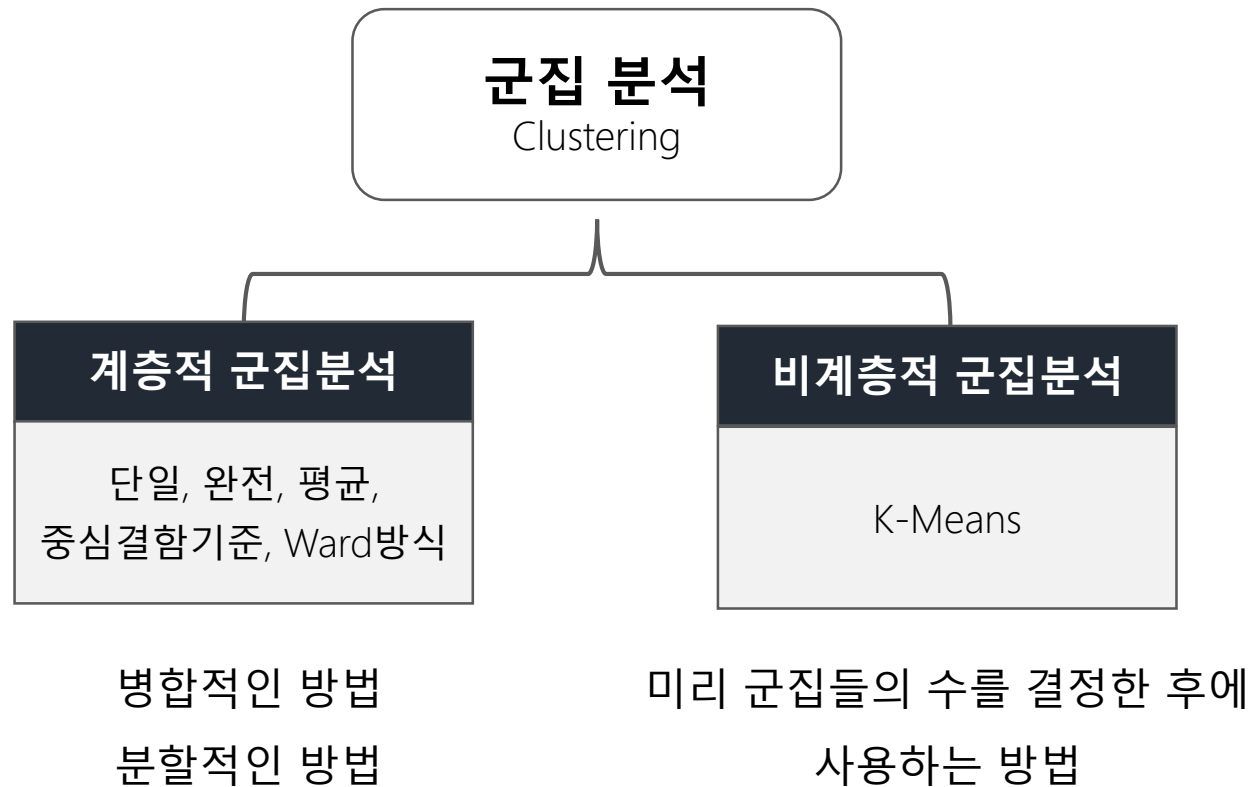
## 2. 머신 러닝의 분류

### 2-2. 비지도 학습

#### 군집 분석

Clustering

군집 분석(Clustering)에는 계층적(Hierarchical Clustering) 방법과 비계층적(Non-Hierarchical Clustering) 방법이 있다.





## 2. 머신 러닝의 분류

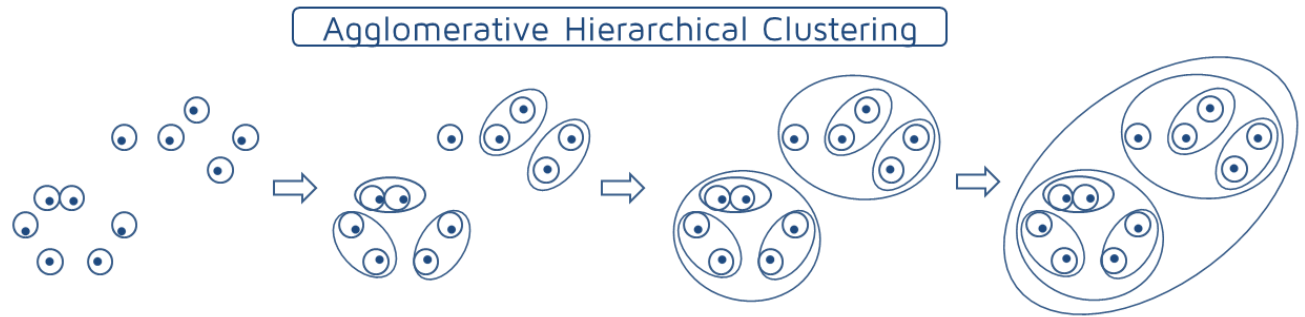
### 2-2. 비지도 학습

#### 군집 분석

Clustering

#### 계층적 군집 분석 - 병합 군집화(Agglomerative Clustering)

- 1) 정확히 하나의 레코드로 구성된 군집들로 시작
- 2) 종료 조건을 만족할 때까지 가장 가까운 두 군집들을 점진적으로 병합해 나감



(이미지: tds, [Hierarchical clustering Clearly Explained](#))

#### 병합 군집화 알고리즘 :

- N개의 군집으로 시작
- 가장 근접한 두 개의 레코드들은 하나의 군집으로 병합(merge)
- 매 단계에서, 가장 거리가 짧은 두 개의 군집들이 병합됨.  
(단일 레코드들이 기존의 군집에 추가되거나, 기존의 군집 두 개가 묶이는 것 의미)

## 2. 머신 러닝의 분류


### 2-2. 비지도 학습

#### 군집 분석

Clustering

#### 계층적 군집 분석 – 덴드로그램(Dendrogram)

군집화 과정을 간략하게 나타내는 나무 형태의 도표



## 2. 머신 러닝의 분류

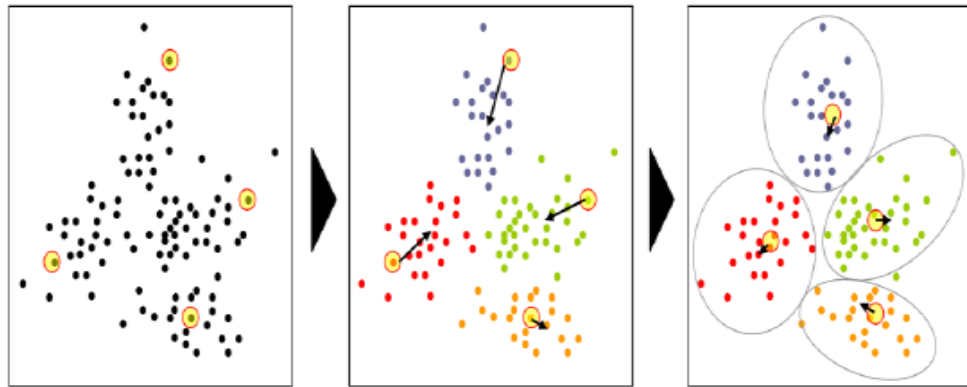
### 2-2. 비지도 학습

#### 군집 분석

Clustering

#### 비계층적 군집 분석 – K 평균 군집화(K-means Clustering)

군집의 중심이 되는 seed(씨드) 집합을 선택하여 그 seed 점과 거리가 가까운 개체들을 그룹화 하는 방법



#### K 평균 군집화 알고리즘 :

- K 개의 관측 값을 선택하여 중심점(centroid)으로 정함
- 각 관측 값들을 '가장 가까운' 중심에 해당하는 군집에 할당
- 새로운 군집에 할당된 관측 값들로 새로운 중심을 계산
- 2)과 3)의 과정을 군집의 중심에 변화가 없을 때까지 반복

※ K 평균 군집분석의 단점: 사전에 군집 수에 대한 예측이 필요하고 처음 선정한 seed 점들에 따라서 군집의 분류가 달라질 가능성 有

## 2. 머신 러닝의 분류

### 2-2. 비지도 학습


#### 차원 축소

Dimensionality  
Reduction

**차원 축소(Dimensionality Reduction)는, 데이터의 의미를 잘 표현하는  
특징(Feature)을 추려내는 것**


#### 특징 추출(Feature Extraction)

- 원본 특징을 기반으로 새로운 특징 벡터를 생성함
- 모든 feature를 온전히 잘 설명하는 원래 벡터보다 작은 feature 벡터로 나타냄

$(X_1, X_2, X_3, X_4, X_5)$    $(Z_1, Z_2, Z_3)$

#### 특징 선택(Feature Selection)

- 전체 입력된 feature 중에서 가장 의미 있는 feature들 만을 선택
- 원본 데이터에서 불필요한 feature(변수)들을 제거

$(X_1, X_2, X_3, X_4, X_5)$    $(X_1, X_3, X_5)$

## 2. 머신 러닝의 분류

### 2-2. 비지도 학습

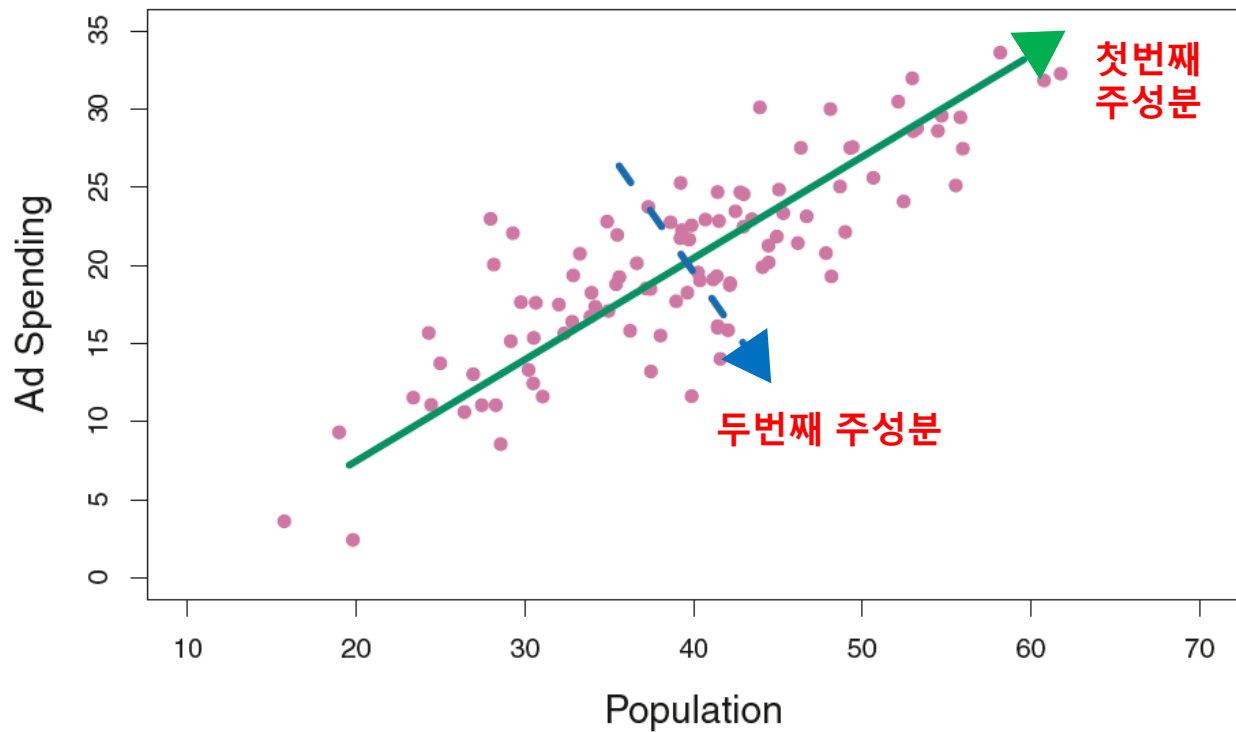
#### 차원 축소

Dimensionality  
Reduction

#### 주성성분분석(Principal Component Analysis, PCA)

PCA는 분포의 주성분(principal component)을 분석해 주는 방법이며, 주성분은 그 방향으로 가장 분산이 큰 벡터를 의미한다.

데이터 주성분 구하기:



### 3. 머신 러닝 모델 평가

#### 수치 예측

Regression Model

#### 모델 평가

#### 회귀 모델(Regression Model)에 대한 성능 평가지표

평가 지표	설명	수식
MAE	Mean Absolute Error이며 실제 값과 예측 값의 차이를 절대값으로 변환해 평균한 것	$\frac{1}{n} \sum_{i=1}^n  y_i - \hat{y}_i $
MSE	Mean Squared Error이며 실제 값과 예측 값의 차이를 제곱해 평균한 것 *MAE값이 같은데 MSE가 클 경우 편차가 더 큼을 나타낸다.	$\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$
RMSE	MSE 값은 오류의 제곱을 구하므로 실제 오류 평균보다 더 커지는 특성이 있으므로 MSE에 루트를 씌운 것이 RMSE(Root Mean Squared Error)다.	$\sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$
R <sup>2</sup>	분산 기반으로 예측 성능을 평가합니다. 실제 값의 분산 대비 예측값의 분산비율을 지표로 하며, 1에 가까울수록 예측 정확도가 높다. *R <sup>2</sup> = 0.91인 경우, 전체 데이터 변동성의 91%를 선형회귀 모델이 설명	$\frac{\sum (\hat{y}_i - \bar{y})^2}{\sum (y_i - \bar{y})^2}$

### 3. 머신 러닝 모델 평가

#### 범주 예측

Classification Model

#### 모델 평가

#### 분류 모델(Classification Model)에 대한 성능 평가지표

혼동 행렬(Confusion Matrix): 데이터의 실제 클래스와 모델에 의해 예측된 클래스를 비교하는 행렬

		PREDICTIVE VALUES		
		POSITIVE (1)	NEGATIVE (0)	
ACTUAL VALUES	POSITIVE (1)	TP = 3	FN = 1	4
	NEGATIVE (0)	FP = 2	TN = 4	6
		5	5	

PRECISION (green box around TP and FP)

RECALL (red box around TP and FN)

$$\text{Accuracy} = (TP + TN) / (TP + FP + TN + FN)$$

$$\text{Recall} = \text{Sensitivity} = TP / (TP + FN) = TP / (\text{Actual Yes})$$

$$\text{Precision} = TP / (TP + FP) = TP / (\text{Predicted Yes})$$

$$\text{F1 Score} = 2 * (\text{Recall} * \text{Precision}) / (\text{Recall} + \text{Precision})$$

### 3. 머신 러닝 모델 평가

## 범주 예측


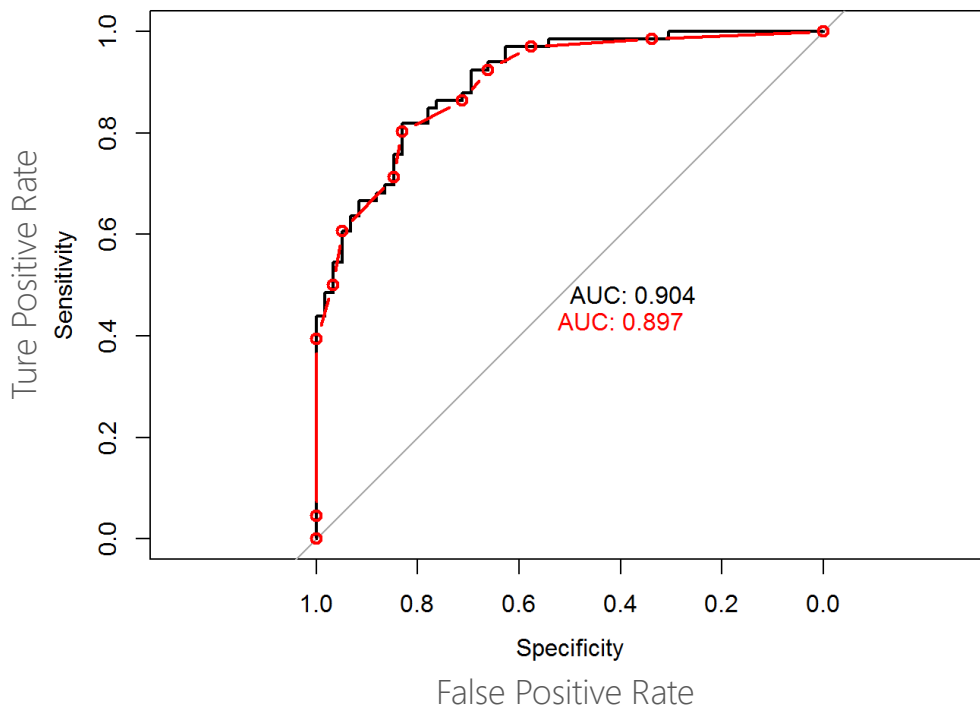
Classification Model

## 모델 평가

## 분류 모델(Classification Model)에 대한 성능 평가지표

ROC(Receiver Operating Characteristic) Curve : FPR과 TPR을 x, y축으로 놓은 그래프

AUC(Area Under the Curve) Score : Curve 아래의 면적을 계산한 것, AUC는 0.5~1의 값을 가지며, 값이 1에 가까울수록 성능이 좋은 모델이다.





### 3. 머신 러닝 모델 평가

#### 범주 예측

Classification Model

#### 모델 평가

#### 분류 모델(Classification Model) - 분류 평가

Model X

		Predicted Class	
		1 (+)	0 (-)
Actual Class	1 (+)	6	4
	0 (-)	50	940

- Accuracy =  $946/1000 = 0.946$
- Recall =  $6 / (6 + 4) = 0.6$
- Precision =  $6 / (6 + 50) = 0.107$
- F1-score = 0.18

Ideal  
Model

		Predicted Class	
		1 (+)	0 (-)
Actual Class	1 (+)	10	0
	0 (-)	0	900

- Accuracy = 1
- Recall = 1
- Precision = 1
- F1-score = 1\* (Best)

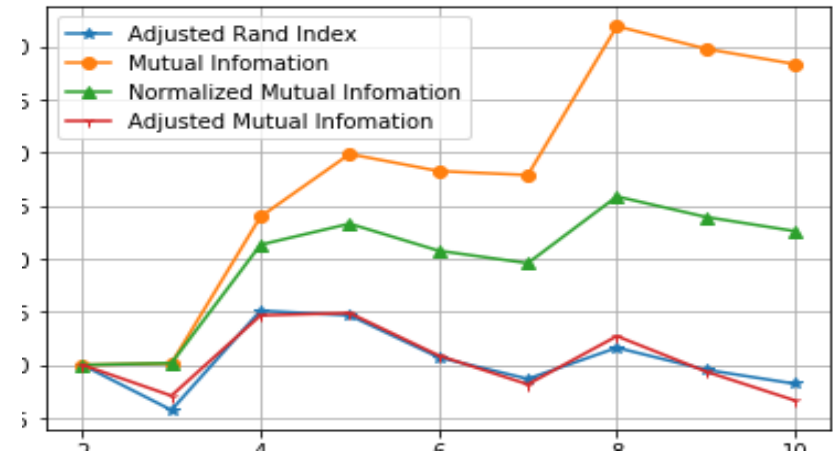
### 3. 머신 러닝 모델 평가

## 클러스터링 Clustering Model 모델 평가

### 군집 모델(Clustering Model) – 클러스터링 평가

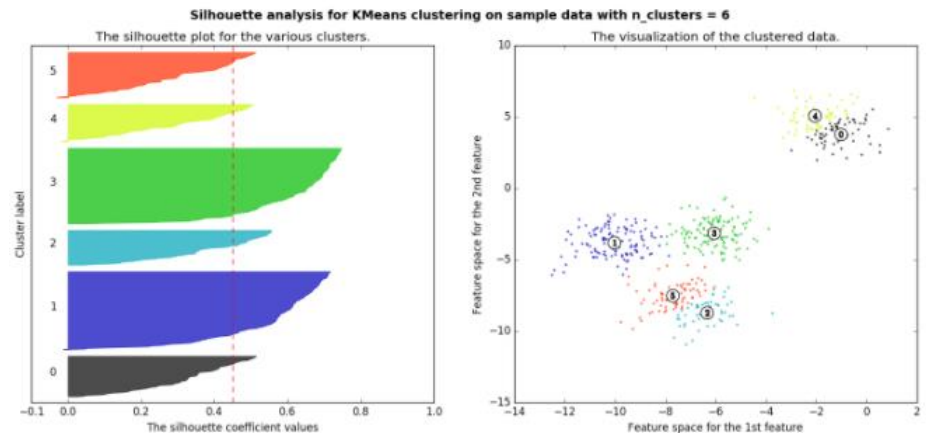
ARI(Adjusted Rand Index):

분류된 군집의 정답 필요



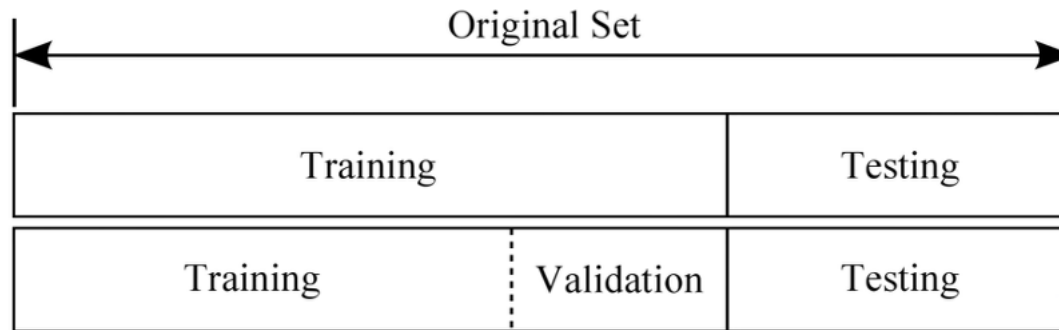
실루엣 계수(Silhouette Coefficient):

군집의 밀집 정도



## 4. 데이터 분할

**데이터셋** Dataset **의** **머신 러닝을 위한 데이터는 Training, Validation, Test 셋으로 나눈다.**  
**종류**



### Training Set

- 모델 생성 및 학습에 이용

### Validation Set

- 모델의 오버피팅(Overfitting) 방지
- 모델의 복잡도 축소
- 모델의 파라미터(Parameter) 탐색

### Test Set

- 모델의 예측 성능(Predictive Performance) 평가

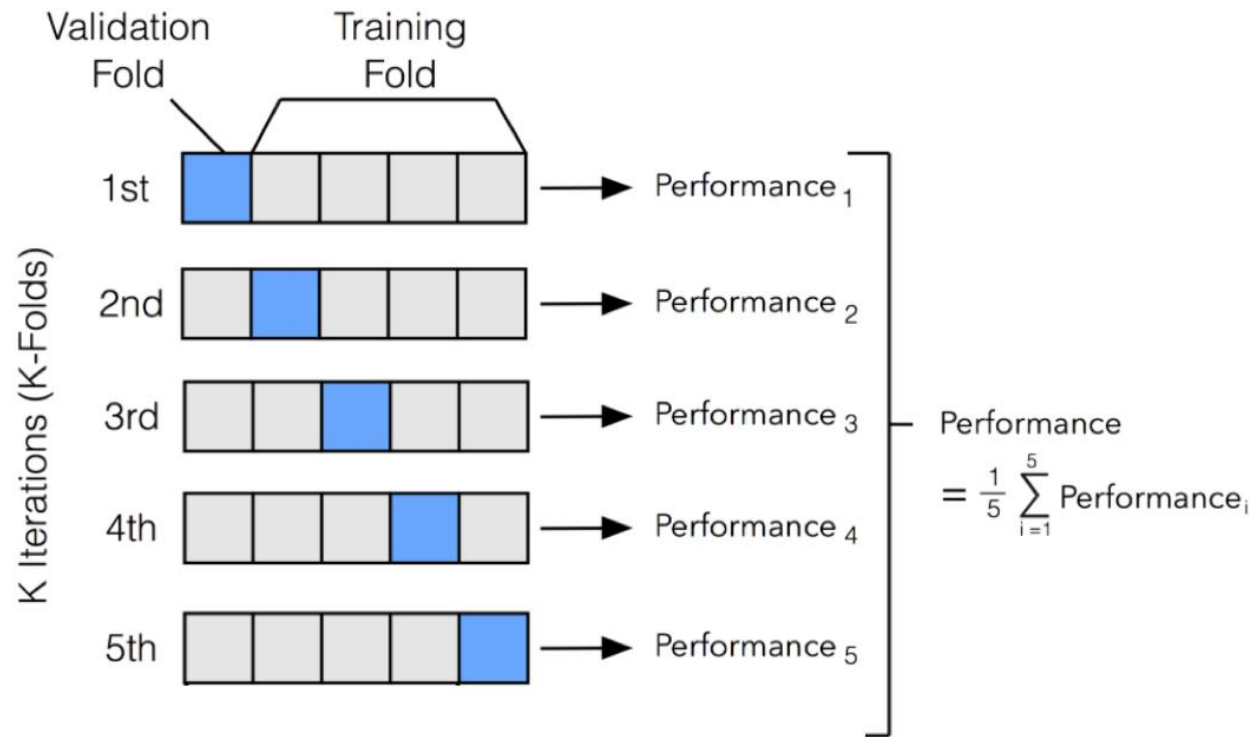
## 4. 데이터 분할

### K-겹 교차 검증

K-fold Cross Validation

K-겹 교차 검증은 모든 데이터가 최소 한 번은 테스트셋으로 쓰이도록 한다.

- 데이터를 K개의 겹치지 않는 folds로 분리
- K개의 folds 중 하나를 Validation Set, 나머지를 Training Set으로 사용
- 하나의 파라미터 셋에 대해 k번 모델을 생성하여 모델 성능 평가



# End of Document

2020. 05